

## Расчетное задание по математической статистике. Часть 3.

### 3.5. Задание

По заданному набору данных двух переменных (приложение 2):

3.1. Проверить гипотезу о независимости переменных по критерию Хи-квадрат (2 балла)

3.2. Вычислить оценку ковариации, коэффициента корреляции (2 балла). Проверить гипотезу о незначимости коэффициента корреляции (2 балла).

3.3. Оценить параметры линейной регрессии (1 балл), вычислить коэффициент детерминации (1 балл), проверить значимость модели по критерию Фишера (2 балла).

Замечание: программе необходимы файлы iris.data , alpha\_table.csv, student\_table.csv , приложенные в письме. В этих файлах содержатся таблицы с данными, необходимыми для решения.

Их необходимо поместить в ту же директорию, из которой запускается сама программа.

Данные из таблицы вариантов для 4 варианта:

- `X = "petal_length"`
- `Y = "sepal_width"`
- `TYPE = "Iris-setosa"`

## 3.1

В этом пункте необходимо проверить гипотезу независимости двух признаков друг от друга.

Алгоритм:

- 1) Вытащить данные из таблицы iris.data, отсортировать их по возрастанию значения в столбце X.
- 2) Преобразовать табличные данные в таблицу сопряженности. (функция create\_partition)
- 3) Вычислить суммы в столбцах и в строках получившейся таблицы сопряженности:

Таблица сопряженности  $X$  и  $Y$  имеет вид:

$X$	$Y$			Всего
	$B_1$	...	$B_k$	
$C_1$	$\nu_{11}$	...	$\nu_{1k}$	$\nu_{1\cdot}$
...	...		...	...
$C_s$	$\nu_{s1}$	...	$\nu_{sk}$	$\nu_{s\cdot}$
Всего	$\nu_{\cdot 1}$	...	$\nu_{\cdot k}$	$n$

где  $\nu_{\cdot k}$  - сумма в  $k$  столбце,  $\nu_{s\cdot}$  - сумма в  $s$  строке,  $n$  - сумма всех  $V_{ij}$  элементов таблицы.

- 4) Вычислить статистику критерия Пирсона:

$$\chi_n^2 = n \sum_{i=1}^s \sum_{j=1}^k \frac{(\nu_{ij} - \nu_{i\cdot} \nu_{\cdot j} / n)^2}{\nu_{i\cdot} \nu_{\cdot j}} = n \left( \sum_{i=1}^s \sum_{j=1}^k \frac{\nu_{ij}^2}{\nu_{i\cdot} \nu_{\cdot j}} - 1 \right)$$

- 5) Получить критическое значение статистики Пирсона по таблице alpha\_table.csv и заданному параметру alpha. (alpha по умолчанию 0.01)

6) Сравнить полученное значение статистики критерия Пирсона с критическим значением, если значение больше критического, гипотеза отвергается.

$$\chi_n^2 > F_{\chi_{(k-1)(k-1)}^2}^{-1}(1 - \alpha),$$

Результат работы программы:

Статистика критерия Пирсона: 23.061324197687828

Критическое значение для alpha == 0.05: 26.3

Значение статистики меньше критического, значит величины независимы, гипотеза принимается.

```
result is 23.061324197687828
function is 26.3
the values are independent
```

### 3.2

В этом пункте нужно вычислить оценку ковариации, коэффициент корреляции. Проверить гипотезу о незначимости коэффициента корреляции.

Алгоритм:

- 1) вычислить выборочные средние и среднее квадратичное для X и Y:

$$\overline{x^2} = \frac{1}{n} \sum_{i=1}^n (x_i)^2, \quad \overline{y^2} = \frac{1}{n} \sum_{i=1}^n (y_i)^2,$$

$\overline{y}, \overline{x}$  - выборочные средние.

- 2) вычислить выборочное стандартное отклонение:

$$s_x^2 = \overline{x^2} - (\overline{x})^2, \quad s_y^2 = \overline{y^2} - (\overline{y})^2$$

$s_x = \sqrt{s_x^2}$  и  $s_y$  - выборочное стандартное отклонение,

- 3) вычислить оценку ковариации:

$$\overline{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i$$

- 4) вычислить выборочный коэффициент линейной корреляции:

$$r_{xy} = \frac{s_{xy}}{s_x s_y},$$

Результат:

оценка ковариации: 0.011448000000000014

коэффициент корреляции: 0.06143539453137004

```
correlation 0.06143539453137004
covariance 0.011448000000000014
```

Проверка гипотезы о незначимости коэффициента корреляции.

Алгоритм:

1)

Распределение статистики

$$T = \frac{r}{\sqrt{1-r^2}} \sqrt{n-2}$$

$r$  - коэффициент корреляции

$n$  - количество элементов выборки

2) вычислить  $t = t_{\alpha, n-2}$  по таблице Стьюдента.  
Если  $T > t$ , то гипотеза отвергается.

Результат:

$T$ : 0.4264424220961077

$t$ : 1.96

$T < t \rightarrow$  гипотеза принимается

```
T == 0.4264424220961077
t == 1.96
the hypothesis of the insignificance
of the linear correlation coefficient is ACCEPTED
```

### 3.3

В этом пункте нужно оценить коэффициенты линейной регрессии, вычислить коэффициент детерминации, проверить значимость модели по критерию Фишера.

Алгоритм:

- 1) Оценим коэффициенты линейной регрессии:

$$\hat{\beta}_0 = \boxed{\bar{y} - \beta_1 \bar{x}}, \quad \hat{\beta}_1 = \frac{\sum_i y_i x_i - n \bar{y} \bar{x}}{\sum_i (x_i)^2 - n (\bar{x})^2}$$

$\bar{y}, \bar{x}$  - выборочные средние.

$$\hat{\beta}_1 == \beta_1$$

- 2) Найдём остаточную вариацию, стандартную ошибку, общую вариацию и вариацию, объяснённую регрессией:

Остаточная вариация (residual sum of squares)

$$RSS = \sum_{i=1}^n (e_i)^2;$$

Стандартная ошибка (несмещенная оценка дисперсии ошибки):

$$s^2 = RSS / (n - m - 1),$$

где  $m = 1$  - число независимых переменных.

Общая вариация

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2;$$

Вариация, объясненная регрессией

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

3)Найдём коэффициент детерминации:

$$R^2 = 1 - RSS/TSS = ESS/TSS; \quad R^2 \in [0,1]$$

4)Рассмотрим гипотезу о значимости регрессии:

Статистика  $F$ -критерия:

$$F = \frac{R^2}{1 - R^2} \frac{n - m - 1}{m},$$

где  $R^2$  - коэффициент детерминации,  $m = 1$  - число независимых переменных.

$H_0$  отвергается на уровне значимости  $\alpha$ , если

$$F > F(\alpha; m, n - m - 1),$$

где  $F(\alpha; m, n - m - 1)$  определяется из таблицы  $F$ -распределения.

Результат:

$\hat{\beta}_1 == \beta_1 == 2.3352464949710456$

$\beta_0 == -0.0008008686376106411$

$R^2 == 0.9351015413611502$

$F == 691.616949411893$

$F(\alpha, m, n - m - 1) == 4.042652128566653$

```
-----  
Beta0 =  -0.0008008686376106411 , Beta1 =  2.3352464949710456  
R^2 ==  0.9351015413611502  
F ==  691.616949411893  
Fisher's criterion ==  4.042652128566653  
The hypothesis is REJECTED at the significance level alpha =  95.0 %  
-----
```